

METEORIX – Questions articles

Questions sur le : YOLO :

1) Nous avons compris de l'article que YOLO adopte une autre idée que les classificateurs qui le précèdent. Au lieu de traiter la détection comme un problème de classification répétée, il la formule comme un problème de régression pour accélérer significativement son processus d'analyse. Cependant, nous ne comprenons pas encore comment ce problème de régression permet à YOLO d'apprendre en une seule étape. **Quel est le mécanisme derrière cette simplification de l'analyse de l'image par : YOLO ?**

2) Nous avons lu les comparaisons des performances sur le jeu de données Pascal VOC 2007 des real-time detectors et des less-than real-time et nous avons constaté que les real-time comme 100Hz DPM sont nettement plus rapides en termes de FPS que les less-than real-time tel que Fast R-CNN, mais leur performance est au contraire moins précise. En effet, 100Hz DPM affiche 100 FPS avec 16% de mAP alors que le Fast R-CNN affiche 0.5 FPS pour 70% de mAP. Les modèles qui ont suivi 100Hz DPM ont amélioré leur mAP mais nous ne sommes pas encore capables d'expliquer **comment ils ont pu réaliser de tels progrès**. DPM sacrifie autant de performance pour gagner en rapidité, et nous ne savons pas encore **si c'est un bon compromis**.

Questions sur le Transformer :

1) Dans l'article "*Attention Is All You Need*", les auteurs mentionnent à plusieurs reprises le mécanisme d'attention, mais sans entrer en détail dans le fonctionnement mathématique ou conceptuel de celui-ci dans les premières sections. Nous avons bien compris l'idée générale, que le modèle apprend à "prêter attention" à certaines parties de la séquence d'entrée, mais nous ne comprenons pas encore le mécanisme précis qui permet à ce processus d'attention de fonctionner. **Pourriez-vous nous expliquer concrètement comment le "attention mechanism" opère ?**

2) Nous avons également remarqué que les auteurs insistent particulièrement sur le rôle du **self-attention**, qui semble être une composante centrale du Transformer. Nous avons lu son explication mais elle reste encore assez abstraite pour nous. Nous aimerions donc comprendre **pourquoi le self-attention est si important et comment il diffère des autres formes d'attention**.

3) Enfin, comme le Transformer ne lit pas les mots un par un comme un CNN qui traite des régions locales de manière séquentielle, nous nous demandons comment il parvient à comprendre la structure d'une phrase. **Comment détecte-t-il quand une phrase est terminée, et plus précisément, comment représente-t-il l'ordre et la position des mots dans la séquence ?**