

METEORIX

Détection des météores à l'aide de la vision embarquée et de l'apprentissage profond

Projet industriel

Polytech Sorbonne, MAIN4, 2025–2026

Paris le 14/4/2026

Auteurs

Adrien PANGUEL

Han CHEN

Victor SOUPRAMANIEN

Mohamed Saad EL ABBADI

Superviseurs

Adrien CASSAGNE

Giulia PERCIBALLI



Exemple de météore


Contexte

Les problématiques :

- ▶ Difficulté de la détection d'un météore.
- ▶ Spécialisation d'un modèle à la détection de météore.
- ▶ Contraintes embarquées : énergie, temps, mémoire.

Notre objectif :

- ▶ Etiquetage automatique des données pour la conception de systèmes embarqués.



Modélisation du nanosatellite Meteorix [1]

[1] N. Rambaux et al. Meteorix : A cubesat mission dedicated to the detection of meteors and space debris. In ESA NEO and Debris Detection Conference Exploiting Synergies–ESA/ESOC, Darmstadt, Germany, 2019.

Etat de l'Art

Approches classiques

- ▶ MeteorScan, MetRec, UFOCapture
- ▶ Projet précédent Météorix [2]

Méthodes pour apprentissage profond

- ▶ Yolo [3]
- ▶ Transformer [4]
- ▶ DETR [5]

[2] Huang, L., Abdou, A., Renaud, C., Poupeau, P., Faucheu, A. (2024–2025). Meteorix. Rapport étudiant, Polytech Sorbonne, spécialité MAIN4. Document non publié.

[3] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You Only Look Once: Unified, Real-Time Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pages 779–788, 2016.

[4] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. Advances in Neural Information Processing Systems (NeurIPS), 2017.

[5] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-End Object Detection with Transformers. European Conference on Computer Vision (ECCV), pages 213–229, 2020.

Planning

Bibliographie

**Recherche de datasets
et annotations**

Spécialisation des modèles

Inférence des modèles

**Ajustement des paramètres
d'entraînement**

**Analyse des résultats, rapport
et poster**

Octobre

Novembre

Décembre

Janvier

Février

Mars

Avril

Sommaire

- 1 Méthodologie & Modèles
- 2 Résultats – Yolo26
- 3 Résultats – DETR
- 4 Conclusion & Pistes d'évolution



Protocole d'expérimentation

Infrastructure de calcul Dalek :

- ▶ **Partition** : az4-n4090
- ▶ **GPU** : NVIDIA GeForce RTX 4090
- ▶ **VRAM** : 24 Go
- ▶ **CPU** : AMD Ryzen 9 7945HX
- ▶ **RAM par nœud** : 96 Go DDR5
- ▶ **Ressources** : 4 nœuds
- ▶ **Utilisation** : entraînement et inférence




Cluster Dalek [6]



Nœud az4-n4090-1 [6]

[6] Dalek Documentation, Description & Topology (partition az4-n4090, photos des nœuds, caractéristiques GPU).

Modèles & Métriques




Architecture de Yolo26 (Ultralytics) [7]
pour la détection d'objets

Modèles :

- **Yolo** : Yolo1, Yolo26.
- **DETR** : DETR avec backbone resnet-50.

Métriques :

- F1-score, Recall, Precision, Inference time, mAP.





Architecture de DETR pour la détection d'objets

[7] Ranjan Sapkota, Rahul Harsha Cheppally, Ajay Sharda, and Manoj Karkee. Yolo26: Key Architectural Enhancements and Performance Benchmarking for Real-Time Object Detection. arXiv preprint arXiv:2509.25164, 2025.

Datasets

Dataset public Mendeley [8] :

- ▶ **Composition** : 7 000 images JPEG du ciel (55% meteor-only, 45% no-meteor).
- ▶ **Période d'acquisition** : entre 2014 et 2023.
- ▶ **Origine géographique** : BRAMON (Brésil), UKMON (R.-U.), BOAM (France).
- ▶ **Split train/valid/test** : selon notre protocole expérimental.
- ▶ **Annotations manuelles** : boîtes englobantes ajoutées manuellement dans le cadre de notre protocole expérimental (non fournies par le dépôt Mendeley).



[8] Gradvohl, Andre; Shirasuna, Victor Yukio (2023), "Image dataset for the creation of an automatic system for meteor fall detection", Mendeley Data, V1, doi: 10.17632/4k98n84d9g.1

Pourquoi spécialiser un modèle ?



Yolo26 :

► Avant spécialisation :

- Oiseau (0.02)
- Personne (0.12)

► Après spécialisation :

- Météore (0.86)



DETR :

► Avant spécialisation :


- Rien du tout (1.0)

► Après spécialisation :

- Météore (0.986)

Résultats – Yolo26

Training et Validation loss – mixed dataset



Paramètres d'entraînement :

- ▶ **Epochs** = 200
- ▶ **Batch** = 16
- ▶ **Time hours** = 0.9

Observations :

- ▶ Décroissance de la training loss
- ▶ Décroissance puis croissance de la validation loss
- ▶ **Nombre d'epochs optimal** : 200

Résultats – Yolo26

Matrice de confusion – mixed dataset, split=test

Confusion matrix for yolo26 - positive class : meteor

Paramètres d'inférence :

► **Confidence threshold** = 60%

Métriques :


► **Recall** = 0.84

► **Precision** = 0.87

Interprétations :

► Bonne détection des vrais météores.


► Proportion non négligeable de FN.



Résultats – Yolo26

Inference time – mixed dataset

YOLO26 inference time deviation from global mean - split=test



Plot :

$$z = \frac{x - \mu}{\sigma}$$

Résultats :

- ▶ **Latence moyenne** = 4.2 ms par image.
- ▶ **FPS** = 233.


Observations :

- ▶ Temps d'inférence très stable.
- ▶ Quelques pics isolés.
- ▶ Légère tendance négative au début.

Résultats – DETR

Training et Validation loss – mixed dataset

DETR training and validation loss (epochs ≤ 70)



Paramètres d'entraînement :

► **Epochs** = 70

► **Batch** = 4

Observations :

► Décroissance de la training loss.


► Décroissance puis convergence de la validation loss.

► **Nombre d'epochs optimal** : 30

Résultats – DETR

Matrice de confusion – mixed dataset, split=test

Confusion matrix for DETR - positive class : meteor



Paramètres d'inférence :

► **Confidence threshold** = 60%

Métriques :

► **Recall** = 0.92

► **Precision** = 0.78

Interprétations :

- Bonne détection des vrais météores.
- Moins de FN que Yolo26.

Résultats – DETR

Inference time – mixed dataset

Plot :

$$z = \frac{x - \mu}{\sigma}$$

Résultats :


► **Moyenne** = 15 ms par image.

► **FPS** = 66.

Observations :

► Temps d'inférence plutôt stable.

► Très gros pic au début.



Résultats – Comparaison

mAP50 – mean Average Precision (≥ 50)





Illustration de l'IoU pour DETR

YOLO26 vs DETR mAP50 on the mixed dataset




Observations :

- ▶ Phase d'apprentissage rapide.
- ▶ Stabilisation à 0.8 :
 - **Yolo26** : CV à 40 epochs.
 - **DETR** : CV à 90 epochs.
- ▶ Yolo26 plus bruité que DETR.
- ▶ Meilleure performance finale de DETR.

Apprentissage from scratch

Une mauvaise idée ?



Raisons :

- ▶ **Dataset trop petit** : 1400 images au lieu de millions.
- ▶ **Diversité** : pas assez de variété dans les données.
- ▶ **Overfitting** : risque de sur-apprentissage du modèle.

Retour sur expérience

Polytech Sorbonne, MAIN4


Han CHEN

Mohamed Saad EL ABBADI

Adrien PANGUEL

Victor SOUPRAMANIEN

Paris, le 8/4/26



Conclusion

	Recall	Precision	F1-score	mAP50	Latence (ms)	σ_{latence} (ms)	FPS
Yolo26	0.84	0.87	0.85	0.85	4.2	0.2	233
DETR resnet-50	0.92	0.78	0.84	0.92	15	3.5	66

Comparaison :

- ▶ **Solution** : étiquetage des données automatique pour la conception de systèmes embarqués.
- ▶ Yolo26 est plus rapide que DETR.
- ▶ DETR a de meilleures prédictions que Yolo26.
- ▶ **Choix du modèle** : Yolo26.
- ▶ **Succès incertain de l'embarqué** : Dalek (450W) contre Nanosatellite (10W).

Pistes d'évolution

- ▶ Validation sur des données plus réalistes et plus variées.
- ▶ Passage de l'image à la vidéo.
- ▶ Optimisation pour l'embarqué.
- ▶ Valorisation scientifique par la rédaction d'un article.

